城市旅游智能体需要收集哪些数据?

从“能做出展示”到“可以完成真实开封行程”的全面数据清单

本文件只围绕一个目标

让游客能把开封的景点、园内演出、美食和城市交通放进同一份行程里，知道何时去、怎么去，途中改变计划后也能继续走下去。**万岁山和清明上河园是重点验证场景，不是整个项目的边界。**

P0
必须具备
景点、商家与菜品关联、演出场次、出入口、交通耗时、用户行程、来源核实。

P1
加强体验
园内主路网、设施、休息点、例外开放规则、预约条件、现场提示。

暂缓
不作为阻塞项
全园实时客流、精确排队时间、海量游客轨迹、训练专用大模型。

这次的数据思路，与之前最大的区别

以前：先想办法拿到两个景区的地图、节目和人流数据。

现在：围绕一次完整旅游任务，收集能决定“去哪、能否去、何时到、要不要改计划”的数据；实时人流不是首版前提。

城市景点 地点与开放规则 › **景区演出** 场次与时间 › **美食商家** 真实供应与营业 › **一份行程** 导航与动态调整

版本：2026-10-20。本文的数量、更新频率是建议执行目标，不表示相关数据已经取得。具体开发权限和接口条款以实际服务合同与控制台为准。

最重要的执行原则

不求一次收全开封，只求第一批数据真实、能互相连接、能完成跨景区与美食的整段游览。

01 先建立一张数据全景图

下面是**整个产品可能用到的主要数据**。P0 必须有可信来源，但不代表都要下载到自己的数据库。

数据域	首版最关键的数据	获得方式	优先级
城市地点	景点、夜市、商家、入口、经纬度	官方资料 + 地点查询 + 核实	P0
开放及入场	营业时段、临时停业、门票、预约、二次入园	官方公告 / 人工核实	P0
景区演出	节目、场次、日期、舞台、取消/调整	景区官方节目单	P0
特色美食	菜品类别、口味、售卖商家、供应证据	人工整理 + 商家核实	P0
城市交通	两地点间路线、时间、距离、交通方式	运行时向高德查询	P0
园内路网	主路口、可通行边、舞台与入口连通	导览资料 + 现场踏勘	P0*
游客行程	可用时间、必去项、当前位置、已完成项	用户主动输入 / 授权	P0
可靠性记录	来源、版本、核实时间、有效期、状态	每条记录同时维护	P0
辅助服务	厕所、休息区、无障碍、天气等	现场及接口	P1
实时拥挤	分区域实时人数、排队时长	需合作或足量样本	暂缓

* 园内路网的“P0”指：若要正式承诺园内路线导航，就必须有可信路网。否则首版只展示位置、官方导览入口或明确标注的示意路线，不能冒充实地导航。

02 一定要分清“存下来”与“随用随查”

适合长期维护

自行核实且有权保存的景区规则、节目场次、商家与特色美食关系、自建园区主路网、数据来源记录。

优先运行时请求

城市路线、交通耗时、当前定位、动态天气等。保留必要的请求记录与结果元数据，缓存遵守服务条款。

不直接收集：“最优路线”“会不会错过节目”“能否顺路吃饭”是系统依据数据算出的结果，不是要事先填进 Excel 的事实。

03 城市景点与游览点：P0 具体字段

字段	记录内容 / 示例形式	为什么必须
基本身份	place_id、名称、类别、景区归属、别名	避免重名、重复和错误匹配
地理位置	经纬度、坐标系、外部 POI ID、地址	地图展示、导航查询
真实到达点	入口 ID、入口坐标、入口开放规则	不能把景区中心点当入口
时间规则	平时开放时间、节假日例外、停止入园时间	判断游览计划是否可执行
访问条件	门票范围、预约要求、二次入园、年龄等特殊规则	避免安排无法进入的行程
体验属性	建议停留时长区间、看点标签、室内/室外	个性化排序和时间预算
可信信息	官网链接、来源记录、核实日、有效期、确认状态	信息变化时能追溯

第一批应该选什么

先选 **8–12 个代表性城市目的地**（建议量级）：两大演艺景区、若干文化景点、夜市或餐饮街区、重要交通衔接点。它们应能组成至少两条实际的一日游路线。

重要但经常被漏掉：一个景区可以有多个入口；一个夜市是“街区”，一个餐馆是“单店”。两者都可以推荐，但不能在数据库里当成同一类地点处理。

04 景点数据从哪里收集

来源	可以先获得什么	必须再核对什么
景区官网 / 公告	正式名称、票务、开放时间、活动	是否为最新日期，节假日变更
高德地点搜索	名称、坐标、地址、地点 ID	是否为真正入口、能否按条款使用
现场观察 / 联系景区	入口、设施、可通行区域	照片/记录是否有使用授权
游客调研	实际停留时间与常见问题	样本量，不把主观经验当事实

最低验收标准：每个用于自动排程的地点都有有效名称、可用到达点、开放规则以及已核实的来源；无法核实则降低功能级别或提示“待确认”。

05 美食模块不要只收集“餐厅名单”

菜品表 food_items

宫廷杏仁茶、花生糕、炒凉粉、开封小笼包等；记录名称、类别、口味标签、适用饮食偏好、简介和介绍来源。

商家表 food_vendors

店名、地址、位置、营业时间、价格参考、堂食/外带、是否景区内、位置与来源核实时间。

一道美食
例如炒凉粉

↔

供应关系
这家店是否确实有售

↔

一个商家
地址与营业规则

需要单独建立“商家—菜品”关系表

字段组	建议字段	核实方式
美食信息	food_id、名称、口味、类别、文化介绍来源	选少量代表性菜品，人工核实
商家信息	vendor_id、店名、POI ID、位置、营业时段	地点查询 + 店方/公开资料
供应关系	food_id + vendor_id、证据链接、核实时间	菜单、商家确认或真实观察
预算信息	价格范围、预计用餐/排队缓冲	先给范围，避免假精确
时空可达	景区内外、离哪处入口较近、是否需出园	与景区及路网数据连接
特殊规则	停售/季节性菜品、休息日、线上核实状态	预约、节假日或临时变化提示

推荐前必须回答两个问题：这家店真的供应用户想吃的食物吗？在用户行程的时间和位置约束下，去这家店是否合理？

06 最小收集规模与不能做的事

首批建议 **10–20 种美食、15–25 家已核实商家、至少 25 条已验证供应关系**。比起导入数百家不确定的餐馆，更重要的是能完成“挑一道菜 → 找到真实商家 → 插入路线”的闭环。

不要因为店在开封、名字里有“宋”或店铺类别是小吃，就推断它出售某种特定菜品。未确认的供应关系不能用于肯定式推荐。

07 演出节目和每一天的场次是两回事

一个节目可能每天上演多次，不同日期的场次也可能不同。务必拆成 **programs**（节目）与 **show_sessions**（场次）两套记录。

数据表	必需字段	用途
节目 programs	program_id、景区 ID、名称、类别、说明、演出舞台 ID、建议提前到场区间	展示和偏好匹配
场次 show_sessions	session_id、program_id、演出日期、开始/结束时间、状态、适用票种	时间窗和冲突判断
场地 stages	stage_id、景区 ID、名称、实际坐标、最近路网节点、场地提示	定位与园内导航
变动记录 schedule_changes	场次 ID、旧值、新值、变更原因、发现时间、来源	防止已取消场次继续推荐
来源快照 sources	节目表链接、公布/核对时间、版本、可用范围	审核与出错追溯

实际获取：先官方、再人工核对

已有可查来源：清明上河园公开节目表包含节目名称、演出地点与多场次时间，可作为候选原始来源。正式使用前仍要确认日期适用范围、网站条款、节目变动方式。万岁山需通过官方节目单、公众号/小程序公开渠道与人工复核建立同类资料。

清明上河园节目表：https://www.qmsyun.com/Mobile_page/o_program.php

刷新与版本策略（建议，不是景区承诺）

什么时候检查	团队应该执行的动作
每天开始前	核对当天节目场次，更新当天有效版本；无法确认时标记“未核实”
游客查询前	检测场次版本是否过期；过期不强行承诺一定开演
官方发布变动时	更新取消、延期、场地变更；保留旧版与变更依据
特殊天气 / 节假日	增设人工复核或明显的“以现场通知为准”提示

缺失字段处理：只有开始时间、没有结束时间时，可提示“结束时间未核实”，先使用注明假设的时长进行演示计算，不把猜测写成官方真实时长。

08 城市道路不需要自己重新采集

两家景区之间、景区到夜市、商家到景点的**实时或近期预计路程**，优先在需要规划时请求高德路径规划服务。不要自行构造全市路网，也不要提前穷举所有地点对的耗时。

数据 / 参数	如何得到	是否建议长期保存
地点坐标与到达点	己方核实的入口 + 地点服务	仅按来源授权处理
步行/公交/驾车方案	调用路径规划 API	优先按需获取；缓存遵守许可
路线距离、预计耗时	从路线结果中读取	保存查询时刻、交通方式与状态
停车/步行到入口/入场缓冲	现场核实或可调节规则	可保存己方实测/估计区间
交通失败 / 无路线	接口错误和无路径响应	记录失败，不凭空补造路线

官方能力：高德路径规划 2.0 提供步行、驾车、公交等接口；POI 搜索 2.0 可做名称、周边、ID 查询。不同接口权限和收费、缓存/展示限制，需按账户和服务条款确认。

09 路上花多久，不等于地图 API 返回多久

出园到出口 园内路网 + **城市通行** 高德估计 + **进园到场地** 园内路网 + **缓冲时间** 可配置规则

举例：游客看完万岁山某场演出，再去清明上河园内一个演出地点。系统需要把“从舞台到出口”“城市交通”“入口到下一个舞台”加起来，不能只拿景区 POI 之间的距离当完整路程。

接口接入还要记录什么

☐ 交通方式 ☐ 请求/返回时间 ☐ 来源 API 版本 ☐ 成功/失败 ☐ 结果是否过期 ☐ 单位（米/秒） ☐ 坐标系 ☐ 缓冲时间规则版本

注意权限：高德开放服务的开发测试、对外上线和商业使用可能有不同的许可条件。开始大规模调用、缓存或对公众开放之前，要查清账户权限与使用条款。

10 园内地图建议收集到什么程度

第一阶段不要求覆盖每一条小路，只要求**入口、重点演出舞台、主干路、关键路口和桥梁彼此连通**，能够支撑真实游览任务。

数据表	最少字段	怎么获得
park_nodes	node_id、景区 ID、经纬度/图上坐标、节点类型、邻近场地	导览图校对 + 现场定位
park_edges	edge_id、from/to 节点、实际长度、步行耗时、是否可通行、方向限制	沿真实主路采集与复核
park_places	入口、舞台、厕所、出口、休息区及关联节点	景区公开资料 + 现场踏勘
map_assets	底图文件、版本、许可、地理配准控制点、坐标转换说明	自绘/授权素材 + 标定
road_exceptions	封闭边、原因、生效时间、恢复时间、来源	可靠公告或现场核查

建议收集流程

选核心点
入口、主舞台
›
连主道路
节点与路段
›
实地核实
能否通行
›
做路线测试
不能穿建筑

为两个景区分别建立路网，并让演出舞台关联到最近的**可通行**节点。可使用 A*/Dijkstra 计算，但算法正确不代表路网就真实。

坐标问题必须在收集时解决

城市地图

高德通常使用 GCJ-02。其他 GPS/OSM 来源可能是 WGS84，混用时要做一致的坐标处理，标记原始坐标系。

古风底图

插画像素坐标不能直接当经纬度。需要控制点、投影或配准；未校准版本只做示意，不称真实导航。

底线：路网没有核实时，宁可先给“位置提示 + 官方导览入口”，也不要输出一条看似精准、实际穿过围墙与水面的路线。

11 一开始要问用户什么？

推荐遵循“先能用，再按需问”。在初次规划时，只收集决定行程是否可行的少量信息。

类型	首版字段 / 获取时机	是否应持久保存
行程边界	开始时间、结束时间、出发点、当天日期	可保存到用户主动创建的行程
硬性偏好	必去景点、指定演出、美食、预算上限	允许用户随时修改
软性偏好	轻松/紧凑、想少走路、兴趣类别	可选，可不保存
位置状态	当前定位、定位精度、获取时间、权限状态	不需要默认长期保存轨迹
实际进展	已到达、跳过、迟到、已完成的行程节点	仅用于行程状态更新
操作结果	用户是否接受建议、手动改路线原因	只有用于评估时才匿名汇总

每一份行程至少需要这些记录

☐ itinerary_id ☐ 用户计划起止时间 ☐ 站点 visit_id ☐ place_id / session_id ☐ 预估停留时长 ☐ 锁定/可替换状态 ☐ 已完成状态 ☐ 交通方式 ☐ 计划版本号

改变计划的关键：把“用户明确必须去的地方”和“系统自己建议的可替换地点”区分开。否则优化算法可能为了减少步行，擅自删除用户最想看的演出。

12 位置和隐私的最低要求

允许拒绝定位

游客可以自己选出发点。请求定位时说明用途；权限拒绝不应导致整个产品不可用。

不长期记录行踪

实时规划优先使用短期位置状态。不默认上传完整历史轨迹；有保存与删除机制。

用户主动输入的预算和口味可以用于当前规划，但不需要为了首版推荐就建立复杂的人物画像。不要未经必要性判断收集身份信息、通讯录、精确连续轨迹。

处理个人位置与行程信息时需遵守中国个人信息保护相关要求，具体实施与上线范围需进一步做合规评估。

13 每条重要数据都要有来源卡片

一个景区营业时间、一条节目场次、一个“某店卖某菜”的关系，都需要能够回答：谁提供的？何时核实？何时可能过期？

字段	建议值 / 作用
source_id / source_url	来源标识与可追溯网址、公告截图或团队现场记录
source_type	official / provider / business / field_check / user_report / mock
observed_at / verified_at	首次观察、最后复核时间，不能只保存录入时间
effective_from / effective_to	适用区间；节目场次须按具体日期存储
confidence / validation_status	已核实、待核实、过期、存在冲突、模拟
reviewer / version	审核人、修改版次及历史记录
rights_status	公开可看不等于可批量抓取、复制或长期存储

14 建议的检查频率

数据	建议复核周期	过期后的处理
当日节目 / 取消	使用前、每日、变更时	显示待核实，不保证仍按原时刻开演
景区规则 / 特殊开放	每周；节假日前额外核对	提示官方确认，暂停强确定性推荐
商家营业与菜品	每周抽查；重要行程临近时复核	标记待确认，不承诺供餐
城市交通	临近出发或重新规划时调用	旧交通结果不能当实时估计
园内路网 / 封闭	每次实地核查；已知变动时	不可靠路段不参与正式导航
用户位置	经同意按需要更新	超时或精度差时提示重新确认

冲突如何处理：官方新公告优先于旧内容；商家信息存在冲突时，不由 AI 自行“猜正确答案”，而是标记待核实。每次重要修改应能查看旧值和来源。

数据可信度和算法同样重要

用户最后只关心：“你推荐的地方究竟开不开门？我按这个计划走会不会白跑？”

15 每类数据的获取方法

内容	首选获取途径	建议执行方式
景点基础信息	景区官网、官方公告 + 高德地点检索	自动发现候选 → 人工核对入口与规则
特色美食与文化	公开权威资料、可授权图文	人工建立菜品分类，记录信息出处
餐饮商家与菜品	店铺公开资料、菜单、店方沟通、实地	先收候选 → 核实售卖关系再上架
每日演出	两个景区官方发布渠道	每日核对场次；维护变更记录
城市路线	高德 Web 服务 API	后端按需调用，控制权限/配额
园内道路和入口	公开导览图 + 现场踏勘	整理节点/边并检查现实可通行性
天气 / 节假日	可靠官方信息 / 合规第三方 API	按需读取，作为规则修正因子
游客体验指标	志愿者可用性测试、任务日志	获知情同意后做匿名评估

16 哪些可以交给 Codex，哪些不能

适合 Codex 自动化

数据表设计、格式标准化、重复去除、字段校验、节目多场次拆分、来源记录、接口封装、变动对比与测试。

仍需要人核实

官网页面的使用权限、某店是否真有售菜、景区二次入园规则、园内道路真实可走、节目临时取消。

采集闭环，不要只追求爬下来多少条

候选数据 带原始来源 › **结构化** 字段统一 › **人工审核** 关键事实确认 › **发布与复核** 可追踪版本

地图/平台数据不能因为 API 可访问就默认允许批量持久化或与其他底图任意混用；上线前核对开放平台使用协议、授权范围、标注要求和来源许可。

17 建议的核心数据表（14 张）

下面是字段主干，不是完整数据库 DDL。可以先按 CSV 导入，后续切换 PostgreSQL。主键都用稳定 ID，不用展示名称做关联键。

表名	最关键字段（示意）	谁来维护
places	place_id, name, type, parent_id, coordinates, status	景点资料负责人
place_entrances	entrance_id, place_id, coordinates, rules	地理资料负责人
open_rules	rule_id, place_id, date_range, open_close, restrictions	资料负责人
food_items	food_id, name, tags, intro_source	美食负责人
food_vendors	vendor_id, place_id, business_hours, price_band	美食负责人
vendor_foods	vendor_id, food_id, evidence, verified_at	美食负责人
programs	program_id, park_id, stage_id, name	演出负责人
show_sessions	session_id, program_id, date, start/end, status	演出负责人
park_nodes	node_id, park_id, x/y or lng/lat, crs	地图负责人
park_edges	edge_id, from_node, to_node, distance, access	地图负责人
itineraries	itinerary_id, starts_at, ends_at, preferences	业务模块
itinerary_stops	stop_id, itinerary_id, place_id/session_id, locked, state	业务模块
source_records	source_id, url, kind, verified_at, expiry, rights	全员共用
change_log	record_key, old/new, source_id, changed_at	审核流程

独立业务版可增加路线请求日志、用户反馈、临时封闭等表。第一版重点不是表多，而是让地点、商家、节目和出入口之间的关联完整。

18 格式与字段统一原则

- ☐ 时间：统一带日期和时区，不能只写“15:30”而不注明哪一天
- ☐ 坐标：明确 GCJ-02 / WGS84 / 底图像素坐标，不能混用
- ☐ 标识：每个节目、场次、商家与舞台都有唯一 ID
- ☐ 状态：unknown / unverified / verified / stale / cancelled / mock 等状态清楚
- ☐ 单位：米、秒、人民币；建议时长与实际观测分开存放

19 首批数据量建议（不要求覆盖全开封）

数据对象	建议首批目标	明确交付物
城市目的地	8–12 个	地点与入口清单、开放规则
景区重点演出	两大景区各选一批代表性节目	节目表 + 独立场次表 + 舞台映射
美食类别	10–20 种	菜品介绍、标签、来源
商家	15–25 家	经核实的位置、营业信息
菜品—商家关系	至少 25 条已核实	可以真实回答“哪家店有这道菜”
园内主干路网	以覆盖代表性任务为准	主入口、舞台、路口和连通关系
城市交通	至少支持步行 + 一种其他交通方式	真实接口查询 + 失败兜底
用户行程样本	不少于 4 个跨场景任务	可复现的测试输入和期望结果

20 两周数据工作建议（可并行推进）

时间	工作重点	完成标志
第 1–2 天	建数据字段表、来源记录模板、景点和节目源清单	表结构定版，来源可追溯
第 3–5 天	收集重点景点、入口、菜品及商家候选	形成有优先级的候选池
第 6–8 天	核实菜品供应、节目场次及两个景区核心节点	主要事实通过人工审核
第 9–11 天	高德接口联调、园内路网连通性测试	能算跨景区 + 城市路线
第 12–14 天	运行四类真实任务、修正错误、形成缺口清单	首版数据验收表与演示结果

两周为参考节奏，不是保证完成的工期。园内路网如果缺少入园踏勘条件，先按“重点点位 + 不承诺真实步行导航”的降级标准交付。

建议分工：工程同学负责数据模型、接口和自动校验；GIS/空间方向同学负责地理数据、路网与坐标核对；景区与美食事实由团队共同完成复核。角色按实际能力逐步调整。

21 不看条数，先看能否完成四个任务

验收任务	需要打通的数据	通过条件
① 跨景区一日游	城市景点、入口、开放、交通时间	能生成合法顺序，不把关门点排进去
② 看两场演出	节目场次、舞台、园内行走预算	识别时间冲突并解释理由
③ 演出间插入美食	菜品、真实商家、营业时间、往返路程	不推荐错误菜品/关门商家
④ 行程临时变化	用户锁定项、已完成项、来源变动	只修改剩余路线，保留必去偏好

22 数据质量的可量化检查

检查点	怎么验
覆盖率	P0 字段非空占比；场次与舞台关联成功率
准确率	从已录入记录随机抽样，复核官网、实地或商家说明
时效性	当天节目是否当天复核；过期数据是否降级
一致性	同名地点去重；舞台 ID 必须存在；时间区间不能颠倒
路线可达性	关键节点必须连通；示意路网不能算真实导航
合规性	数据来源可追溯；授权/版权未明的数据禁止对外使用

最关键的失败兜底

- ☐ 演出没有最新表 → 不承诺会准点开演，提示官方再次确认
- ☐ 商家菜品没核实 → 不给肯定式“这家店一定有”
- ☐ 高德接口失败 → 允许切到外部导航，或提示重新规划
- ☐ 园内路网没有验证 → 停用精准路线，只保留位置指引
- ☐ 用户拒绝位置授权 → 手动选择起点仍可继续

这一版的数据验收标准

至少完成“景点 → 演出 → 美食 → 城市交通 → 临时调整”的真实闭环，并且每个关键事实都有来源、每个不确定环节都有诚实的降级处理。

23 已查到的公开资料入口

以下为2026-10-20核查时可用于确定采集方法的资料入口，不代表已经获得全部景区数据，也不代表取得批量抓取或永久存储权限。

资料 / 平台	可核实的能力或用途
清明上河园公开节目表 https://www.qmsyun.com/Mobile_page/o_program.php	节目名称、演出地点、多场次时间；用于结构设计及人工核对。
高德路径规划 2.0 https://lbs.amap.com/api/webservice/guide/api/newroute	步行、公交、驾车等城市路径与预计耗时。
高德地点搜索 2.0 https://lbs.amap.com/api/webservice/guide/api-advanced/newpoisearch	地点关键词、周边、ID 查询；不是完整商家菜单数据库。
高德坐标系说明 https://lbs.amap.com/faq/advisory/others/39838	高德地图采用 GCJ-02；采集的 GPS 坐标需正确转换。
OSM 许可说明 https://www.openstreetmap.org/copyright	OSM 可作为候选地理数据来源，使用需遵守 ODbL、署名及衍生数据库条件。
中国个人信息保护法 相关法律原文（工信部门站点）	定位、用户偏好和行程数据的收集需要遵循必要性、告知与授权等原则。

24 开始填表前，团队先统一五项约定

- ☐ 每条数据必须有唯一 ID 与来源字段；未核实数据不能直接进入正式推荐。
- ☐ 日期、时区、长度、价格、坐标系统一格式；节目必须细到独立场次。
- ☐ 先确认数据来源许可，再决定是否程序抓取、缓存、存档和公开展示。
- ☐ 实际核实与预测/模拟严格分开，不因模型生成而提升可信度。
- ☐ 先做可运行的最小数据集，按用户任务扩张，而不是按网站数量扩张。

收集数据不是为了填满数据库。
是为了让游客的下一步，真正走得通。

随文附带的 ZIP 中另有可直接填写的 CSV 模板，涵盖景点、出入口、演出场次、菜品、商家、供应关系、园内路网与来源记录。模板字段是第一版建议，可随验证反馈迭代。